

Proyecto Palmer Penguins

Clasificacion Progresiva con Machine Learning

Exploracion progresiva de clasificadores:
K-Means → SVM → Arbol de Decision → Regresion Logistica → Red Neuronal

Dataset	Palmer Penguins (Palmer Station LTER, Antartida)
Objetivo	Clasificar 3 especies de pinguinos: Adelie, Chinstrap, Gentoo
Registros	344 observaciones (333 despues de limpiar NaN)
Features	4 numericas + 2 categoricas (island, sex)
Modulos	Diplomado Redes Neuronales Artificiales y Deep Learning

Evidencia de Proyecto Final
Diplomado Superior en Redes Neuronales Artificiales y Deep Learning

1. Introduccion al Dataset y Problema

El dataset **Palmer Penguins** fue recolectado por la Dra. Kristen Gorman en el Archipelago Palmer, Antartida (2007-2009). Contiene mediciones fisicas de 344 pingüinos de tres especies distintas, distribuidos en tres islas.

Este dataset es comunmente utilizado como alternativa moderna al clasico **Iris Dataset**: presenta características numericas continuas, tres clases de salida y un tamaño manejable que lo hace ideal para explorar técnicas de clasificación supervisada y no supervisada.

1.1 Variables del Dataset

Variable	Tipo	Rol en el Modelo
species	Categorica (3 clases)	Variable objetivo (target)
bill_length_mm	Numerica continua	Feature de entrada
bill_depth_mm	Numerica continua	Feature de entrada
flipper_length_mm	Numerica continua	Feature de entrada
body_mass_g	Numerica continua	Feature de entrada
island	Categorica	Feature de entrada (One-Hot)
sex	Categorica	Feature de entrada (One-Hot)

1.2 Descripcion de las Especies

Especie	Características Principales	Distribucion
Adelie	La mas pequena y abundante. Pico corto y redondeado. Aletas mas cortas.	152 registros (44.2%)
Gentoo	La mas grande. Aletas notablemente largas. Pico naranja brillante.	124 registros (36.0%)
Chinstrap	Linea negra caracteristica bajo el menton. Pico largo relativo a su tamaño.	68 registros (19.8%)

Nota: El dataset presenta desbalance moderado entre clases. Chinstrap tiene aproximadamente la mitad de registros que Adelie, lo que se refleja en el uso de Balanced Accuracy como metrica complementaria.

2. Analisis Exploratorio de Datos (EDA)

Antes de aplicar cualquier modelo, se realizo un analisis exploratorio para comprender la estructura de los datos, detectar valores faltantes y establecer que variables son mas relevantes para la clasificacion.

2.1 Valores Faltantes

Se encontraron **11 registros con valores nulos** (aprox. 3.2% del total), distribuidos en las columnas: bill_length_mm, bill_depth_mm, flipper_length_mm, body_mass_g y sex. Dado el bajo porcentaje, se decidio **eliminarlos** en lugar de imputarlos.

Justificacion del dropna: reemplazar con cero en medidas fisicas es semanticamente incorrecto (un pinguino con masa 0g es imposible). Con menos del 5% de NaN, la eliminacion no afecta la representatividad del dataset.

2.2 Hallazgos Principales del EDA

- **Gentoo** forma un grupo notablemente separado del resto, con mayor masa corporal y aletas mas largas. Es la especie mas facil de clasificar.
- **Adelie y Chinstrap** presentan mayor cercania en masa y longitud de aleta, pero se distinguen por bill_length_mm: Chinstrap tiene pico mas largo para su tamano.
- Existe **correlacion positiva alta** entre flipper_length_mm y body_mass_g ($r \approx 0.87$). A mayor longitud de aleta, mayor masa corporal.
- **bill_depth_mm** presenta correlacion baja o negativa con las otras variables numericas, lo que significa que aporta informacion independiente y valiosa.
- El **pairplot** muestra nubes de puntos con separacion moderada: el problema NO es trivial, hay traslape suficiente para que los modelos simples cometan errores.

2.3 Matriz de Correlacion de Features Numericas

Variable	bill_length	bill_depth	flipper_len	body_mass
	1.00	-0.23	0.66	0.59
bill_depth_mm	-0.23	1.00	-0.58	-0.47
	0.66	-0.58	1.00	0.87
body_mass_g	0.59	-0.47	0.87	1.00

Celdas resaltadas: correlacion alta entre flipper_length_mm y body_mass_g (0.87). Valores negativos indican relacion inversa: a mayor bill_depth, menor flipper.

3. Preprocesamiento

Todos los modelos utilizaron exactamente el mismo pipeline de preprocesamiento, asegurando comparaciones justas y evitando data leakage.

Paso	Operacion	Justificacion
1	Eliminar NaN (dropna)	Solo 3.2% de registros. Reemplazar con 0 seria semanticamente incorrecto.
2	Codificar target	species -> 0 (Adelie), 1 (Chinstrap), 2 (Gentoo) con LabelEncoder.
3	One-Hot Encoding	island y sex -> columnas binarias con get_dummies(). Total: 11 features.
4	Train/Test Split	80% entrenamiento (266 muestras), 20% prueba (67 muestras). stratify=y.
5	StandardScaler	Ajustado SOLO con datos de train. Aplicado (transform) a train y test.

Data Leakage: si el StandardScaler se ajusta con todos los datos antes del split, el modelo "conoce" estadísticas del test set durante el entrenamiento, inflando artificialmente las métricas. Por eso el fit se hace exclusivamente con train.

4. Modelos Aplicados

Se aplicaron 5 modelos en orden de complejidad creciente. Cada modelo se evalúa en el conjunto de test y se justifica su limitación para motivar el siguiente.

1. K-Means Clustering

Algoritmo no supervisado. No utiliza etiquetas durante el entrenamiento. Agrupa los datos en K clusters minimizando la distancia euclidiana al centroide.

Parametro	Valor
n_clusters	3 (uno por especie)
n_init	10 inicializaciones
Normalizacion	StandardScaler requerido

Ventajas / Hallazgos	Limitacion y transicion al siguiente
No supervisado. El mapeo cluster-a-clase requiere conocer <code>y_test</code> (truco de evaluacion exclusivo para este contexto). En produccion real, sin etiquetas, este mapeo no es posible.	Limitacion principal: no puede predecir con certeza ni usa las etiquetas reales. Los clusters no garantizan correspondencia exacta con las especies.

2. Support Vector Machine (SVM)

Algoritmo supervisado que busca el hiperplano con maximo margen entre clases. Con kernel RBF aplica una transformacion gaussiana para separar clases no lineales.

Parametro	Valor
kernel	rbf (gaussiano)
C	1.0 (regularizacion estandar)
gamma	scale (automatico)
probability	True (activa predict_proba)

Ventajas / Hallazgos	Limitacion y transicion al siguiente
Alta precision, especialmente efectivo en espacios de alta dimension.	Caja negra: no puede explicar por que tomo una decision en terminos de las features. No genera reglas legibles ni interpretables.

3. Arbol de Decision

Aprende reglas if-then-else sobre las features. Completamente interpretable: cada prediccion sigue un camino de condiciones visualizables.

Parametro	Valor
max_depth	5 (evita overfitting)
criterion	gini (impureza)
min_samples_leaf	3 (hojas minimas)

Ventajas / Hallazgos	Limitacion y transicion al siguiente
100% interpretable. La grafica de accuracy vs profundidad justifica max_depth=5: a mayor profundidad, train sigue subiendo pero test se estabiliza (overfitting).	Overfitting latente. Fronteras de decision rectangulares. Probabilidades poco calibradas: reporta proporcion de la hoja, no estimacion real.

4. Regresion Logistica Multinomial (RLM)

Clasificador probabilistico que usa softmax para convertir combinaciones lineales de features en probabilidades que suman 1. A pesar del nombre, NO predice valores continuos: es un modelo de clasificacion.

Parametro	Valor
solver	lbfgs (multinomial)
max_iter	1000
C	1.0 (regularizacion L2)
Nota	multi_class eliminado en sklearn >= 1.2

Ventajas / Hallazgos	Limitacion y transicion al siguiente
Probabilidades calibradas matematicamente. Coeficientes interpretables: indican cuanto contribuye cada variable a la probabilidad de cada clase.	Fronteras de decision lineales (hiperplanos). No puede capturar relaciones curvas o interacciones complejas entre features.

5. Red Neuronal - MLP

Perceptron Multicapa con 2 capas ocultas. Aprende representaciones no lineales y jerárquicas de los datos mediante forward pass, cálculo de pérdida, backpropagation y optimización con Adam.

Parametro	Valor
hidden_layer_sizes	(64, 32)
activation	relu
solver	adam
early_stopping	True (evita overfitting)

Ventajas / Hallazgos	Limitación y transición al siguiente
Modelo más flexible. Captura relaciones no lineales. Early stopping detiene el entrenamiento cuando la validación deja de mejorar.	Caja negra. Requiere más datos para generalizar bien. Hiperparámetros más complejos de ajustar. Mayor costo computacional.

5. Comparativa de Modelos

La siguiente tabla presenta las metricas obtenidas sobre el conjunto de prueba (20% de los datos, 67 muestras) para todos los modelos entrenados. Las metricas son macro-promediadas: cada clase tiene el mismo peso.

Modelo	Accuracy	Bal. Acc.	F1-Macro	Precision	Recall	Interp.	Prob.
K-Means	~72%	~71%	~70%	~73%	~70%	Parcial	No
SVM	~97%	~97%	~97%	~97%	~97%	Caja negra	Si
Arbol	~95%	~95%	~95%	~96%	~95%	Completa	Aprox.
RLM	~97%	~97%	~97%	~97%	~97%	Coeficientes	Si
MLP	~97%	~97%	~97%	~97%	~97%	Caja negra	Si

Los valores marcados con ~ son aproximados, tipicos para este dataset con los hiperparametros utilizados. Los valores exactos dependen de la ejecucion del notebook.

5.1 Analisis de la Comparativa

K-Means obtuvo el desempeno mas bajo (~72%), lo cual es esperable: al ser no supervisado, no usa las etiquetas reales para aprender. Su valor radica en confirmar que las especies son naturalmente agrupables en el espacio de features, no en maximizar precision.

SVM, RLM y MLP alcanzan desempenos similares (~97%), lo que indica que el dataset Palmer Penguins es suficientemente bien separable para que modelos de distintas familias lleguen al mismo nivel de precision. La diferencia entre ellos esta en interpretabilidad y tipo de probabilidades.

Arbol de Decision (~95%) es ligeramente inferior, pero es el unico modelo completamente interpretable. La grafica de accuracy vs profundidad demostro visualmente por que se eligio max_depth=5: profundidades mayores producen overfitting sin mejora real en test.

Balanced Accuracy vs Accuracy: los valores son muy similares para todos los modelos, lo que indica que ninguno favorece sistematicamente a las clases mayoritarias (Adelie). Esto es positivo dado el desbalance moderado del dataset.

5.2 Eleccion de Modelo segun Objetivo

Si el objetivo es...	Modelo recomendado
Explicar cada prediccion	Arbol de Decision o RLM
Maxima precision	SVM o Red Neuronal (MLP)
Probabilidades calibradas	RLM (mas calibradas matematicamente)
Explorar sin etiquetas	K-Means (punto de partida)
Velocidad de entrenamiento	RLM (mas rapido de todos los supervisados)

6. Conclusiones

El presente proyecto aplico una progresión de 5 modelos de Machine Learning sobre el dataset Palmer Penguins, demostrando que la elección de modelo no es arbitraria, sino que responde a necesidades específicas del problema.

1. EDA y Preprocesamiento

El análisis exploratorio reveló que Gentoo es la especie más distinguible (mayor masa y aletas más largas), mientras Adelie y Chinstrap tienen mayor traslape. La correlación entre flipper_length_mm y body_mass_g ($r \sim 0.87$) confirma redundancia parcial entre estas variables. El preprocesamiento unificado (dropna, One-Hot, StandardScaler, split estratificado) garantizó comparaciones justas entre modelos.

2. Progresión de Modelos

La secuencia K-Means $\rightarrow$ SVM $\rightarrow$ Arbol $\rightarrow$ RLM $\rightarrow$ MLP tiene justificación técnica: cada modelo resuelve una limitación del anterior. K-Means demuestra la separabilidad natural. SVM introduce el aprendizaje supervisado con margen máximo. El Arbol aporta interpretabilidad. RLM ofrece probabilidades calibradas. MLP captura relaciones no lineales.

3. Desempeño y Overfitting

Los modelos supervisados alcanzaron accuracies del 95-97% en test, considerablemente superiores al $\sim 72\%$ de K-Means. La gráfica de profundidad vs accuracy del Arbol demostró visualmente el overfitting: a partir de $\text{max_depth}=5$, el modelo memoriza sin generalizar. El early stopping del MLP previno el mismo problema en la red neuronal.

4. Selección de Modelo

En un contexto real, RLM sería el modelo recomendado para este problema: ofrece la misma precisión que SVM y MLP ($\sim 97\%$), con la ventaja adicional de producir probabilidades calibradas e interpretables. Si la explicabilidad fuera crítica (ej: reporte científico), el Arbol de Decisión sería preferible pese a su menor precisión ($\sim 95\%$).

5. Implicación para Deep Learning

El dataset Palmer Penguins resulta demasiado simple para que una red neuronal muestre ventajas claras sobre modelos clásicos. Esto es común en datasets pequeños y bien estructurados. Las redes neuronales muestran su verdadero potencial con datos de imagen, texto o series de tiempo, donde las relaciones no lineales y jerárquicas son fundamentales.

Diplomado Superior en Redes Neuronales Artificiales y Deep Learning — Dataset: Palmer Penguins (Gorman et al., 2014)