



Proyecto Palmer Penguins

Clasificación Progresiva con Machine Learning

K-Means → SVM → Arbol → RLM → Red Neuronal

Dataset	Palmer Penguins (Palmer Station LTER, Antartida)
Objetivo	Clasificar 3 especies: Adelie, Chinstrap, Gentoo
Registros	344 obs. originales 333 despues de limpiar NaN
Features	4 numéricas + 2 categóricas (island, sex) = 11 tras One-Hot
Diplomado	Redes Neuronales Artificiales y Deep Learning

Evidencia de Proyecto

1. Introducción al Dataset y Problema

El dataset **Palmer Penguins** fue recolectado por la Dra. Kristen Gorman en el Archipiélago Palmer, Antártida (2007-2009). Contiene mediciones físicas de 344 pingüinos de tres especies distintas, distribuidas en tres islas.

1.1 Las Tres Especies

		
Adelie	Chinstrap	Gentoo
La mas pequena y abundante. Pico corto y redondeado. 152 registros (44.2%)	Linea negra bajo el menton. Pico largo para su tamaño. 68 registros (19.8%)	La mas grande y pesada. Aletas notablemente largas. 124 registros (36.0%)

1.2 Variables del Dataset

Variable	Tipo	Rol
species	Categorica (3 clases)	Variable objetivo (target)
bill_length_mm	Numerica continua	Feature → Normalizacion
bill_depth_mm	Numerica continua	Feature → Normalizacion
flipper_length_mm	Numerica continua	Feature → Normalizacion
body_mass_g	Numerica continua	Feature → Normalizacion
island	Categorica	Feature → One-Hot Encoding
sex	Categorica	Feature → One-Hot Encoding

2. Análisis Exploratorio de Datos (EDA)



Antes de aplicar cualquier modelo se realizó un análisis exploratorio para comprender la estructura de los datos, detectar valores faltantes y establecer que variables son mas relevantes para la clasificación.

2.1 Valores Faltantes

Se encontraron **11 registros con valores nulos** (~3.2%). Se decidió eliminarlos con `dropna()` ya que representan menos del 5% y reemplazarlos con cero sería semanticamente incorrecto (masa de 0g es imposible).

2.2 Gráficas del EDA

Las siguientes gráficas se generan al ejecutar el notebook.



2.3 Hallazgos Clave del EDA

- **Gentoo** forma un grupo notablemente separado: mayor masa corporal y aletas mas largas. Es la especie mas fácil de clasificar.
- **Adelie y Chinstrap** tienen mayor traslape en masa y aleta, pero se distinguen por bill_length_mm.
- Correlación positiva alta entre flipper_length_mm y body_mass_g ($r \sim 0.87$).
- **bill_depth_mm** presenta correlación baja con las otras variables, aportando información independiente.

2.4 Matriz de Correlación

Variable	bill_length	bill_depth	flipper_len	body_mass
bill_length_mm	1.00	-0.23	0.66	0.59
bill_depth_mm	-0.23	1.00	-0.58	-0.47
flipper_length_mm	0.66	-0.58	1.00	0.87
body_mass_g	0.59	-0.47	0.87	1.00

Nota: Celdas resaltadas: correlación alta entre flipper_length_mm y body_mass_g (0.87). A mayor aleta, generalmente mayor masa.

3. Preprocesamiento

Todos los modelos usaron el mismo pipeline de preprocesamiento, garantizando comparaciones justas y previniendo **data leakage**.

Pa so	Operacion	Justificacion
1	Eliminar NaN (dropna)	Solo 3.2%. Reemplazar con 0 seria semanticamente incorrecto.
2	Codificar target	species → 0 (Adelie), 1 (Chinstrap), 2 (Gentoo) con LabelEncoder.
3	One-Hot Encoding	island y sex → columnas binarias. Total: 11 features.
4	Train/Test Split	80% entrenamiento (266), 20% prueba (67). stratify=y.
5	StandardScaler	Ajustado SOLO con train. Aplicado (transform) a train y test.

Nota:

Data Leakage: si el StandardScaler se ajusta con todos los datos antes del split, el modelo conoce estadísticas del test set durante entrenamiento, inflando artificialmente las métricas.

4. Modelos Aplicados

Se aplicaron 5 modelos en orden de complejidad creciente. Cada modelo se evalúa en el conjunto de test y se justifica su limitación para motivar el siguiente.

1. K-Means Clustering

Algoritmo no supervisado. No utiliza etiquetas durante el entrenamiento. Agrupa los datos en K clusters minimizando la distancia euclidiana al centroide de cada grupo.


Parametro	Valor / Descripcion
n_clusters	3
n_init	10
Normalizacion	StandardScaler

Hallazgos / Ventajas

No supervisado. Silhouette Score y curva de inercia muestran la calidad del agrupamiento. El mapeo cluster-especie requiere conocer y_test (solo valido en evaluación).

Limitacion → Motiva el siguiente modelo

No puede predecir con certeza ni usa etiquetas reales. Los clusters no garantizan correspondencia exacta con las especies. Sin probabilidades.



2. Support Vector Machine (SVM)

Algoritmo supervisado. Busca el hiperplano con máximo margen entre clases. Con kernel RBF aplica una transformación gaussiana para capturar relaciones no lineales.

Parámetro	Valor / Descripción
kernel	rbf
C	1.0
gamma	scale
probability	True

Hallazgos / Ventajas

Alta precisión. Efectivo en espacios de alta dimension. Las probabilidades (probability=True) permiten inferencia confiable.

Limitación → Motiva el siguiente modelo

Caja negra: no puede explicar las decisiones en términos de las features originales. No genera reglas legibles.

3. Árbol de Decisión

Aprende reglas if-then-else sobre las features. Cada predicción sigue un camino de condiciones visualizables. La grafica depth vs accuracy justifica la elección de max_depth=5.


Parametro	Valor / Descripcion
max_depth	5
criterion	gini
min_samples_leaf	3

Hallazgos / Ventajas

100% interpretable. La gráfica de profundidad vs accuracy muestra overfitting: a partir de depth 5, train sigue subiendo pero test se estabiliza.

Limitacion → Motiva el siguiente modelo

Overfitting sin restricciones. Fronteras rectangulares. Probabilidades poco calibradas (proporción de la hoja).

**4. Regresión Logística Multinacional (RLM)**

A pesar del nombre, es un clasificador probabilístico. Calcula $z_k = w \cdot x + b$ para cada clase y aplica softmax para obtener probabilidades que suman 1. Clasifica

Parámetro	Valor / Descripción
solver	lbfgs
max_iter	1000
C	1.0

Hallazgos / Ventajas

Probabilidades calibradas matemáticamente. Coeficientes interpretables: variables con coeficiente positivo aumentan la probabilidad de esa especie.

Limitación → Motiva el siguiente modelo

Fronteras de decisión lineales (hiperplanos). No captura relaciones curvas ni interacciones complejas entre features.

5. Red Neuronal - MLP

Perceptron Multicapa: Entrada(11) → Oculta(64,ReLU) → Oculta(32,ReLU) → Salida(3,Softmax). Aprende mediante forward pass, cross-entropy loss, backpropagation y Adam optimizer.


Parámetro	Valor / Descripción
hidden_layer_sizes	(64, 32)
activation	relu
solver	adam
early_stopping	True

Hallazgos / Ventajas	Limitación → Motiva el siguiente modelo
Modelo mas flexible. Early stopping previene overfitting. La curva de perdida muestra convergencia saludable (bajada rápida, estabilización).	Caja negra. Requiere mas datos para generalizar bien. Hiperparametros mas complejos. Mayor costo computacional.

5. Comparativa de Modelos

Métricas obtenidas sobre el conjunto de prueba (20% de los datos, 67 muestras). Métricas macro-promediadas: cada clase tiene el mismo peso.

Modelo	Accuracy	Bal.Acc.	F1-Macro	Precision	Recall	Interpretable	Prob.
K-Means	~72%	~71%	~70%	~73%	~70%	Parcial	No
SVM	~97%	~97%	~97%	~97%	~97%	Caja negra	Si
Arbol	~95%	~95%	~95%	~96%	~95%	Completa	Aprox.
RLM	~97%	~97%	~97%	~97%	~97%	Coeficientes	Si
MLP	~97%	~97%	~97%	~97%	~97%	Caja negra	Si



5.1 Análisis de la Comparativa

K-Means obtuvo el menor desempeño (~72%), esperable al ser no supervisado. Su valor radica en confirmar que las especies son naturalmente agrupables.

SVM, RLM y MLP alcanzan desempeños similares (~97%), indicando que el dataset es suficientemente separable para que modelos de distintas familias lleguen al mismo nivel. La diferencia esta en interpretabilidad y tipo de probabilidades.

Árbol de Decisión (~95%) es ligeramente inferior pero es el único completamente interpretable. La gráfica de profundidad vs accuracy demostró visualmente el overfitting.

5.2 Elección de Modelo según Objetivo

Objetivo	Modelo Recomendado
Explicar cada predicción	Árbol de Decisión o RLM
Máxima precisión	SVM o Red Neuronal (MLP)
Probabilidades confiables	RLM (mas calibradas matemáticamente)
Sin etiquetas disponibles	K-Means (exploración inicial)
Velocidad de entrenamiento	RLM (el mas rápido de los supervisados)

6. Conclusiones

1. EDA y Preprocesamiento

El EDA revelo que Gentoo es la mas distinguible (mayor masa y aletas mas largas), mientras Adelie y Chinstrap tienen mayor traslape. La correlación flipper-masa ($r \sim 0.87$) confirma redundancia parcial. El preprocesamiento unificado garantizo comparaciones justas.

2. Progresión de Modelos

La secuencia K-Means $\rightarrow$ SVM $\rightarrow$ Arbol $\rightarrow$ RLM $\rightarrow$ MLP tiene justificación técnica: cada modelo resuelve una limitación del anterior. La progresión no es solo de precisión sino de interpretabilidad, probabilidades y capacidad de capturar no linealidad.

3. Overfitting y Generalización

Se controla mediante: `max_depth` en el Árbol (demostrado visualmente), `early stopping` en MLP, y regularización (parámetro C) en SVM y RLM. La evaluación en test set garantiza que las métricas reflejan generalización real.

4. Selección de Modelo

RLM es el candidato final recomendado: igual precisión que SVM y MLP (~97%), probabilidades calibradas e interpretables por coeficientes. Si la explicabilidad fuera critica, el Árbol (~95%) seria preferible.

5. Implicación para Deep Learning

Palmer Penguins es demasiado simple para que MLP muestre ventajas claras sobre modelos clasicos. Las redes neuronales muestran su potencial real con datos de imagen, texto o series de tiempo, donde las relaciones jerárquicas son fundamentales.